

CLOUD SYSTEM ANOMALY DETECTION BASED ON SEMANTIC LOG PARSING USING LOCAL OPEN-SOURCE LLMS

Trường Đại học Công Nghệ Thông Tin
Đại học Quốc Gia Thành Phố Hồ Chí Minh

250202060 - Nguyễn Long Vũ

University of Information Technology HCMC, Vietnam


What ?

- Đề xuất và đánh giá một pipeline phát hiện bất thường end-to-end cho hệ thống cloud, chạy hoàn toàn offline không phụ thuộc API ngoài
- Tái hiện SemanticLog bộ phân tích log ngữ nghĩa dựa trên LLaMA-3.1-8B với kiến trúc sửa đổi loại bỏ causal mask, chuyển từ text generation sang token classification
- Tích hợp đầu ra ngữ nghĩa vào mô hình phát hiện bất thường LogFormer và PLELog

Why ?

- Log chứa thông tin nhạy cảm doanh nghiệp → không thể gửi lên API online vi phạm chính sách bảo mật
- Parser truyền thống bỏ qua ngữ nghĩa tham số log chỉ dùng wildcard <*> → mất thông tin quan trọng cho anomaly detection
- Chưa có nghiên cứu đánh giá hệ thống và toàn diện tác động của mức độ ngữ nghĩa log lên anomaly detection

Overview



Description

1. SemanticLog LogLLM

- Nền tảng: LLaMA-3.1-8B, loại bỏ causal mask → bidirectional attention
- Fine-tune với LoRA rank=12, alpha=32, dropout=0.1 trên 1 GPU RTX 3090 (24GB VRAM)
- Chuyển từ text generation sang token classification tránh hallucination
- Lấy mẫu ~4.5% dữ liệu có nhãn để train tiết kiệm chi phí annotate
- Thời gian train dự kiến: ~2.1 giờ (toàn bộ LogHub-2.0)
- Cross-source split: train 13 nguồn, test 1 nguồn → đánh giá zero-shot generalization

Ví dụ: Semantic log parsing

```
Input: "Connection status: 0"
↓ SemanticLog ↓
Template: "Connection status:
<SID>"
SID =
Status Indicator

Input: "blk_-1608 from
/10.2.1.5:50010"
↓ SemanticLog ↓
Template: "<OID> from <LOI>"
OID = Object ID LOI =
Location
```

2. SemPerception + EffiParsing

- SPM: multi-head cross-attention tổng hợp subword → 1 vector thống nhất cho token dài (URL, file path, ID phức tạp)
- Learnable semantic vector VSA được tối ưu qua quá trình train → phân loại ngữ nghĩa chính xác hơn
- EffiParsing Tree: prefix tree cố định độ sâu → tránh tree imbalance trên log phức tạp
- Jaccard similarity matching tại leaf node → chính xác, nhanh

HỆ THỐNG 16 NHÃN NGỮ NGHĨA:



★ = 6 nhãn mới mà VALB 10 nhãn thô không có đặc biệt ERR và OBO rất quan trọng cho anomaly detection vì lỗi và thứ tự sự kiện là 2 dấu hiệu bất thường phổ biến nhất trong log thực tế.

3. Anomaly Detection

- Tích hợp với LogFormer (transformer 2-stage, pre-train + adapter) và PLELog (semi-supervised, GRU attention)
- Dataset: BGL (kernel boot log) và HDFS (Hadoop distributed log) từ LogPAI
- 6 thực nghiệm: 2 mô hình × 3 mức nhãn ngữ nghĩa
- Ablation: case study log phân loại sai ở baseline nhưng đúng với 16 nhãn tinh
- Semantic label giúp tăng Recall phát hiện được các bất thường tinh vi hơn

KẾT QUẢ DỰ KIẾN:

LogFormer – BGL dataset	
Baseline (no label)	88.1%
10 nhãn thô (VALB)	88.4%
16 nhãn tinh ★	≥90.1%
PLELog – HDFS dataset	
Baseline (no label)	90.4%
10 nhãn thô (VALB)	91.9%
16 nhãn tinh ★	≥93.1%